

DESAFIO 06 – PREVISÃO DE CONSUMO DE ENERGIA ELÉTRICA

1. Introdução

O objetivo deste trabalho foi desenvolver modelos de regressão capazes de prever o consumo de energia elétrica residencial a partir da variável Global Active Power, utilizando dados do conjunto Household Electric Power Consumption.

A previsão de consumo energético possui aplicações importantes em planejamento de demanda, otimização da distribuição elétrica e desenvolvimento de sistemas inteligentes de gerenciamento de energia. Para isso, foram aplicadas técnicas de análise exploratória, engenharia de atributos e modelagem preditiva utilizando algoritmos de aprendizado de máquina.

2. Análise Exploratória dos Dados

Inicialmente foi realizada uma análise exploratória para compreender o comportamento do consumo energético ao longo do tempo.

A distribuição da variável-alvo apresentou forte assimetria à direita, indicando que a maior parte das observações corresponde a baixos níveis de consumo, enquanto eventos de alto consumo ocorrem com menor frequência. Esse comportamento evidencia a presença de picos de demanda e possíveis valores extremos.

A análise temporal revelou significativa variabilidade ao longo do período analisado, demonstrando que o consumo elétrico não permanece constante. Foram identificados padrões associados aos hábitos de utilização dos equipamentos elétricos pelos moradores.

Ao observar o consumo por hora do dia, verificou-se que os menores valores ocorrem durante a madrugada, enquanto os maiores níveis de consumo concentram-se principalmente no período noturno. Esse comportamento confirma a relevância das variáveis temporais como potenciais preditoras do consumo futuro.

3. Pré-processamento dos Dados

As etapas de preparação dos dados incluíram:

- Conversão das variáveis de data e hora para formato datetime;
- Extração de atributos temporais (hora, dia da semana, mês e indicador de final de semana);
- Criação de variáveis defasadas (lags de 1 hora e 24 horas);
- Tratamento de valores ausentes;
- Normalização dos atributos numéricos;
- Divisão cronológica dos dados para treinamento, validação e teste.

A utilização de variáveis temporais e defasadas foi importante para capturar padrões históricos de consumo e dependências temporais presentes na série.

4. Modelagem

Foram avaliados três modelos de regressão:

- Regressão Linear;
- Regressão Polinomial;
- Random Forest Regressor.

O modelo Random Forest apresentou os melhores indicadores quantitativos de desempenho, obtendo valores elevados de coeficiente de determinação (R^2) e baixos erros médios.

Os gráficos de valores reais versus preditos demonstraram forte proximidade entre as previsões e os valores observados. Da mesma forma, a análise dos resíduos indicou distribuição próxima de zero, sem padrões evidentes de erro sistemático.

Entretanto, uma análise metodológica mais aprofundada revelou uma limitação importante no processo de modelagem.

5. Discussão Metodológica e Limitações

Embora os resultados obtidos tenham sido excelentes, parte desse desempenho pode ser explicada pela presença de data leakage (vazamento de informação).

Durante a construção do conjunto de atributos foram utilizadas variáveis como:

- Global Reactive Power;
- Voltage;
- Global Intensity;
- Sub-meterings.

Essas variáveis são registradas no mesmo instante temporal da variável-alvo Global Active Power e possuem elevada correlação física e estatística com o consumo que se deseja prever.

Na prática, isso significa que o modelo teve acesso a informações contemporâneas ao próprio valor que deveria prever, tornando a tarefa artificialmente mais fácil. Como consequência, os indicadores de desempenho obtidos provavelmente superestimam a capacidade preditiva real do modelo em um cenário operacional.

Em uma aplicação real, ao tentar prever o consumo futuro, essas informações do mesmo instante temporal ainda não estariam disponíveis. Dessa forma, variáveis históricas, como os lags de consumo e atributos temporais, representam um conjunto de características mais adequado para uma previsão genuinamente prospectiva.

Portanto, embora o modelo tenha apresentado métricas excepcionais, esses resultados devem ser interpretados com cautela devido à influência das variáveis contemporâneas.

6. Importância das Variáveis

A análise de importância das variáveis demonstrou que os atributos diretamente relacionados ao consumo elétrico tiveram grande influência nas previsões.

Contudo, é importante distinguir entre:

Variáveis contemporâneas

- Global Reactive Power;
- Voltage;
- Global Intensity;
- Sub-meterings.

Essas variáveis possuem forte associação com o consumo do mesmo instante e contribuíram significativamente para o elevado desempenho observado.

Variáveis genuinamente preditivas

- Hora do dia;
- Dia da semana;
- Mês;
- Indicador de final de semana;
- Lag de 1 hora;
- Lag de 24 horas.

Essas características refletem informações que estariam disponíveis antes da ocorrência do consumo futuro e, portanto, representam o núcleo preditivo mais confiável do modelo.

7. Conclusão

O estudo demonstrou a aplicação de técnicas de aprendizado de máquina para previsão de consumo energético residencial, destacando o Random Forest como o modelo com melhor desempenho entre os algoritmos avaliados.

A análise exploratória evidenciou padrões temporais relevantes, especialmente relacionados ao horário do dia e ao histórico recente de consumo.

Entretanto, a avaliação crítica dos resultados revelou a presença de data leakage decorrente da utilização de variáveis medidas simultaneamente ao consumo alvo. Essa característica contribuiu para métricas extremamente elevadas e limita a interpretação do desempenho como capacidade real de previsão futura.

Como trabalho futuro, recomenda-se reconstruir o modelo utilizando exclusivamente variáveis históricas e temporais, eliminando informações contemporâneas ao target. Essa abordagem permitirá uma avaliação mais rigorosa da capacidade preditiva do sistema e produzirá resultados mais representativos de um cenário real de previsão de consumo energético.